


به نام خدا

پیش‌بینی بیماری قلبی



سرکار خانم حوری رضوی

ریحانه بنیادی

پاییز ۴۰۳

مقدمه:

در این پروژه، ما به بررسی یک مجموعه داده می‌پردازیم که معیارهای سلامتی مختلف بیماران قلبی، مانند سن، فشار خون، ضربان قلب و موارد دیگر را در بر می‌گیرد. هدف ما ایجاد یک مدل پیش‌بینی است که قادر به شناسایی دقیق افراد مبتلا به بیماری قلبی باشد. با توجه به پیامدهای جدی از دست دادن یک تشخیص مثبت، تأکید اصلی ما بر این است که اطمینان حاصل کنیم که مدل همه بیماران بالقوه را شناسایی می‌کند.

توضیح داده‌ها:

	age	sex	cp	trtbps	chol	fbs	restecg	thalachh	exng	oldpeak	slp	caa	thall	output
0	63	1	3	145	233	1	0	150	0	2.3	0	0	1	1
1	37	1	2	130	250	0	1	187	0	3.5	0	0	2	1
2	41	0	1	130	204	0	0	172	0	1.4	2	0	2	1
3	56	1	1	120	236	0	1	178	0	0.8	2	0	2	1
4	57	0	0	120	354	0	1	163	1	0.6	2	0	2	1

متغیر	توضیحات
age	سن بیمار به سال
sex	جنسیت بیمار (۰ = مرد، ۱ = زن)

نوع درد قفسه سینه: ۰: آنژین معمولی ۱: آنژین غیر معمولی ۲: درد غیر آنژین ۳: بی علامت	cp
فشار خون استراحتی به mm Hg	restbps
کلسترول به mg/dl	chol
سطح قند خون ناشتا (بالای ۱۲۰ = ۱، در غیر این صورت = ۰)	fbs
نتایج الکتروکاردیوگرام استراحتی: ۰: نرمال ۱: وجود ناهنجاری موج ST-T ۲: نشان دهنده احتمال یا نوع مشخصی از هایپرتروفی بطن چپ	restecg
حداکثر ضربان قلبی که در طول تست استرس به دست می آید	thalach
آنژین ناشی از ورزش (۱ = بله، ۰ = خیر)	exang
کاهش ST ناشی از ورزش نسبت به استراحت	oldpeak
شیب اوج segment ST در ورزش: ۰: صعودی ۱: تخت ۲: نزولی	slope
تعداد رگ های اصلی (۴-۰) رنگ آمیزی شده با فلوروسکوپی	ca

نتیجه تست استرس تالیوم: ۰: نرمال ۱: نقص ثابت ۲: نقص قابل برگشت ۳: توصیف نشده	thal
وضعیت بیماری قلبی (۰ = بدون بیماری، ۱ = وجود بیماری)	output

Preprocessing:

تعداد سطرها: مجموعه داده شامل ۳۰۳ سطر است.

ستون‌ها: ۱۴ ستون در مجموعه داده وجود دارد که مربوط به ویژگی‌های مختلف بیماران و نتایج آزمایشات است.

انواع داده‌ها:

اکثر ستون‌ها (۱۳ از ۱۴) از نوع داده int64 هستند.

فقط ستون oldpeak از نوع داده float64 است.

مقادیر از دست رفته: خوشبختانه هیچ مقدار از دست رفته‌ای نداریم.

توجه: بر اساس انواع داده‌ها و توضیحات ویژگی‌هایی که قبلاً داشتیم، می‌بینیم که ۹ ستون (sex, cp, fbs, restecg, exang, slope, ca, thal, target) با وجود اینکه از نظر نوع داده عددی هستند، اما از نظر معنایی آنها categorical هستند. این ویژگی‌ها باید به نوع داده رشته‌ای (شیء) برای تجزیه و تحلیل و تفسیر مناسب تبدیل شوند.

خلاصه آماری داده‌ها:

	age	trtbps	chol	thalachh	oldpeak
count	303.000000	303.000000	303.000000	303.000000	303.000000
mean	54.366337	131.623762	246.264026	149.646865	1.039604
std	9.082101	17.538143	51.830751	22.905161	1.161075
min	29.000000	94.000000	126.000000	71.000000	0.000000
25%	47.500000	120.000000	211.000000	133.500000	0.000000
50%	55.000000	130.000000	240.000000	153.000000	0.800000
75%	61.000000	140.000000	274.500000	166.000000	1.600000
max	77.000000	200.000000	564.000000	202.000000	6.200000

	sex	cp	fbs	restecg	exng	slp	caa	thall	output
count	303	303	303	303	303	303	303	303	303
unique	2	4	2	3	2	3	5	4	2
top	1	0	0	1	0	2	0	2	1
freq	207	143	258	152	204	142	175	166	165

داده‌های پیوسته:

age: میانگین سنی بیماران تقریباً ۵۴.۴ سال است که جوانترین آنها ۲۹ و مسن ترین آنها ۷۷ سال است.

trestbps: میانگین فشار خون در حالت استراحت حدود ۱۳۱.۶۲ میلی متر جیوه است که از ۹۴ تا ۲۰۰ میلی متر جیوه متغیر است.

chol: میانگین سطح کلسترول تقریباً ۲۴۶.۲۶ میلی گرم در دسی لیتر و حداقل ۱۲۶ و حداکثر ۵۶۴ میلی گرم در دسی لیتر است.

thalach: میانگین حداکثر ضربان قلب به دست آمده در حدود ۱۴۹.۶۵ با دامنه بین ۷۱ تا ۲۰۲ است.

oldpeak: میانگین افسردگی ST ناشی از ورزش نسبت به استراحت حدود ۱.۰۴ است که مقادیر آن از ۰ تا ۶.۲ متغیر است.

داده‌های گسسته:

sex: دو مقدار منحصر به فرد وجود دارد که زنان (که با ۱ مشخص می شود) متداول ترین دسته است که ۲۰۷ بار از ۳۰۳ ورودی رخ می دهد.

cp: چهار نوع منحصر به فرد درد قفسه سینه وجود دارد. رایج ترین نوع "۰" است که ۱۴۳ بار رخ می دهد.

fbs: دو دسته وجود دارد و پرتکرارترین دسته "۰" (نشان دهنده قند خون ناشتا کمتر از ۱۲۰ میلی گرم در دسی لیتر) است که ۲۵۸ بار ظاهر می شود.

restecg: سه نتیجه منحصر به فرد وجود دارد. رایج ترین نتیجه "۱" است که ۱۵۲ بار ظاهر می شود.

exang: دو مقدار منحصر به فرد وجود دارد. بیشترین مقدار "۰" است (نشان دهنده عدم وجود آنژین ناشی از ورزش)، که ۲۰۴ بار مشاهده شده است.


slope: سه شیب منحصر به فرد وجود دارد. متداول ترین نوع شیب "۲" است که ۱۴۲ بار رخ می دهد.

ca: پنج مقدار منحصر به فرد برای تعداد عروق اصلی رنگ شده توسط فلوروسکوپی وجود دارد که "۰" بیشترین فراوانی را دارد و ۱۷۵ بار رخ می دهد.

thal: چهار نتیجه منحصر به فرد در دسترس است. رایج ترین نوع آن "۲" است (نشان دهنده یک نقص برگشت پذیر) که ۱۶۶ بار مشاهده شده است.

هدف: دو مقدار منحصر به فرد وجود یا عدم وجود بیماری قلبی را نشان می دهد. مقدار "۱" (نشان دهنده وجود بیماری قلبی) بیشترین فراوانی را دارد که در ۱۶۵ بار مشاهده شده است.

نمودار هیستوگرام داده‌های پیوسته:



سن (age): توزیع تا حدودی یکنواخت است، اما اوج آن در اواخر دهه ۵۰ وجود دارد.

فشار خون در حالت استراحت (trestbps): فشار خون در حالت استراحت برای اکثر افراد در حدود ۱۲۰-۱۴۰ میلی متر جیوه است.


کلسترول (chol): سطح کلسترول اکثر افراد بین ۲۰۰ تا ۳۰۰ میلی گرم در دسی لیتر است.

حداکثر ضربان قلب به دست آمده (thalach): اکثر افراد در طول تست استرس ضربان قلب خود را بین ۱۴۰ تا ۱۷۰ ضربان در دقیقه می‌رسند.

افسردگی ST ناشی از ورزش (oldpeak): بیشتر مقادیر روی ۰ متمرکز شده‌اند، که نشان می‌دهد بسیاری از افراد افسردگی ST قابل توجهی را در طول ورزش تجربه نکرده‌اند.

پس از بررسی هیستوگرام ویژگی‌های پیوسته، به نظر می‌رسد هیچ نویز قابل توجه یا مقادیر غیرقابل قبولی در بین متغیرهای پیوسته وجود ندارد.

نمودار توزیع داده‌های گسسته:



جنسیت (sex): مجموعه داده ها عمدتاً زن هستند و اکثریت قابل توجهی را تشکیل می دهند.

نوع درد قفسه سینه (cp): مجموعه داده انواع مختلف درد قفسه سینه را در بین بیماران نشان می دهد. به نظر می رسد نوع * (آنژین معمولی) شایع ترین باشد.

قند خون ناشتا (fbs): اکثریت قابل توجهی از بیماران دارای سطح قند خون ناشتا زیر ۱۲۰ میلی گرم در دسی لیتر هستند که نشان می دهد قند خون بالا یک وضعیت رایج در این مجموعه داده نیست.

نتایج الکتروکاردیوگرافی در حالت استراحت (restecg): نتایج نشان می دهد که نتایج الکتروکاردیوگرافی در حال استراحت متفاوت است، که انواع خاصی از آن ها شایع تر از سایرین است. توزیع دقیق را می توان از روی نمودارها اندازه گیری کرد.


آنژین ناشی از ورزش (exang): اکثر بیماران آنژین ناشی از ورزش را تجربه نمی کنند، که نشان می دهد ممکن است این یک علامت رایج در بین بیماران این مجموعه داده نباشد.

شیب اوج segment ST در ورزش (slope): مجموعه داده، شیب های مختلف بخش ST تمرین اوج را نشان می دهد. یک نوع خاص ممکن است رایج تر باشد و توزیع آن را می توان از نمودارهای نواری استنباط کرد.

تعداد عروق اصلی رنگ شده توسط فلوروسکوپی (ca): اکثر بیماران رگ های اصلی کمتری دارند که توسط فلوروسکوپی رنگ می شوند که عدد صفر بیشترین فراوانی را دارد.

نتیجه تست استرس تالیم (thal): مجموعه داده انواعی از نتایج تست استرس تالیم را نشان می دهد. به نظر می رسد یک نوع خاص شایع تر است، اما توزیع دقیق آن را می توان در نمودارها مشاهده کرد.

تحلیل نمودار Boxplot متغیرهای پیوسته:



سن (Age): توزیع سن بین افرادی که بیماری قلبی دارند (خروجی = ۱) و افرادی که ندارند (خروجی = ۰) تفاوت قابل توجهی ندارد.

میانهای سن برای هر دو گروه نزدیک به هم است که نشان می‌دهد سن به‌تنهایی شاخص قوی برای تشخیص بیماری قلبی در این داده‌ها نیست.

فشار خون در حالت استراحت (trestbps): فشار خون در حالت استراحت برای هر دو گروه مشابه است، اما مقادیر کمی بالاتر در گروه بدون بیماری قلبی (خروجی = ۰) مشاهده می‌شود. نقاط پرت در هر دو گروه دیده می‌شود که نشان‌دهنده وجود افرادی با فشار خون بالا است.

کلسترول (chol) : سطح کلسترول در هر دو گروه مشابه است و محدوده‌ی بین چارکی (IQR) نیز تا حد زیادی با هم همپوشانی دارد.

وجود نقاط پرت در هر دو گروه نشان می‌دهد که سطح کلسترول به تنهایی نمی‌تواند تمایز قوی بین افراد با و بدون بیماری قلبی ایجاد کند.

حداکثر ضربان قلب (thalach) : افراد دارای بیماری قلبی (خروجی = ۱) به طور کلی حداکثر ضربان قلب پایین‌تری نسبت به افراد بدون بیماری قلبی دارند.

تعداد نقاط پرت برای حداکثر ضربان قلب در افراد بدون بیماری قلبی کمتر است.

افسردگی ST ناشی از ورزش (oldpeak) : افراد دارای بیماری قلبی (خروجی = ۱) افسردگی ST ناشی از ورزش کمتری نسبت به افراد بدون بیماری قلبی دارند.

تفاوت در میانه و محدوده‌ی بین چارکی نشان می‌دهد که این ویژگی می‌تواند عاملی متمایزکننده برای بیماری قلبی باشد.

تعداد رگ‌های اصلی (ca) : تعداد رگ‌های اصلی که از طریق فلوروسکوپی رنگ‌آمیزی شده‌اند، در افراد بدون بیماری قلبی بیشتر است.

وجود نقاط پرت و مقادیر کمتر در افراد دارای بیماری قلبی نشان‌دهنده اهمیت این ویژگی برای تمایز است.


نتیجه تست استرس تالیوم (thal) : توزیع مقادیر thal بین دو گروه متفاوت است. افرادی که بیماری قلبی ندارند، تمایل به داشتن مقادیر بالاتر در این ویژگی دارند که نشان‌دهنده نتایج بهتر تست است.

محدوده‌های بین چارکی کمتر همپوشانی دارند که نشان می‌دهد این ویژگی می‌تواند برای تمایز مهم باشد.

ویژگی‌های کلیدی متمایزکننده: ویژگی‌های thal، oldpeak، ca و thal تفاوت‌های بیشتری بین گروه‌ها نشان می‌دهند و احتمالاً برای پیش‌بینی بیماری قلبی اهمیت بیشتری دارند.

ویژگی‌های دارای همپوشانی: ویژگی‌های age، chol و trestbps همپوشانی زیادی دارند و به‌تنهایی قدرت پیش‌بینی قوی‌ای ندارند.

بررسی نمودار Scatterplot ویژگی‌های پیوسته:



سن (Age): نمودار نشان می‌دهد که توزیع سنی بین دو گروه (افراد دارای بیماری قلبی و افراد بدون بیماری) تا حد زیادی همپوشانی دارد.

افراد دارای بیماری قلبی (نقاط نارنجی) به طور کلی کمی در بازه‌ی سنی بالاتر تمرکز دارند، اما این تفاوت جزئی است.

فشار خون در حالت استراحت (trestbps): در محورهای مرتبط با فشار خون در حالت استراحت، داده‌ها بین دو گروه همپوشانی زیادی دارند.

این ویژگی به‌تنهایی تفاوت مشخصی بین دو گروه ایجاد نمی‌کند.

کلسترول (chol): توزیع سطح کلسترول نیز مشابه ویژگی قلبی همپوشانی زیادی بین دو گروه دارد.

در پراکندگی داده‌ها، نقاط با سطح کلسترول بالا در هر دو گروه مشاهده می‌شوند، اما برای افراد بدون بیماری، این مقادیر بیشتر متمرکز هستند.

حداکثر ضربان قلب (thalach): افراد دارای بیماری قلبی (خروجی = ۱) معمولاً حداکثر ضربان قلب کمتری دارند. این ویژگی در نمودار پراکندگی و توزیع به وضوح دیده می‌شود.

این تفاوت می‌تواند به عنوان یک شاخص مهم در مدل‌سازی پیش‌بینی بیماری قلبی مورد استفاده قرار گیرد.


افسردگی ST ناشی از ورزش (oldpeak): توزیع افت قطعه ST بین دو گروه تفاوت چشمگیری دارد.

افراد بدون بیماری قلبی (خروجی = ۰) معمولاً مقادیر افت بیشتری دارند که این ویژگی را به عنوان یک شاخص بالقوه مهم معرفی می‌کند.

ویژگی‌هایی که بیشترین توانایی تفکیک بین دو گروه را دارند: oldpeak , thalach

نمودار تحلیل ویژگی‌های گسسته:

Categorical Features vs Output Stacked Barplots



تعداد رگ‌های اصلی (ca): اکثر بیماران مبتلا به بیماری قلبی رگ‌های اصلی کمتری دارند که توسط فلوروسکوپی رنگ شده است. با افزایش تعداد عروق رنگی، نسبت بیماران مبتلا به بیماری قلبی کاهش می‌یابد. به خصوص، بیمارانی که رگ‌های ۰ رنگی دارند، نسبت بیشتری از بیماری قلبی را دارند.

نوع درد قفسه سینه (cp): انواع مختلف درد قفسه سینه نسبت‌های متفاوتی از بیماری قلبی را نشان می‌دهد. شایان ذکر است، انواع ۱، ۲ و ۳ نسبت بیماری قلبی بالاتری نسبت به نوع ۰ دارند. این نشان می‌دهد که نوع درد قفسه سینه می‌تواند در پیش‌بینی بیماری موثر باشد.

آنژین ناشی از ورزش (exang): بیمارانی که آنژین ناشی از ورزش را تجربه نکردند (۰) نسبت بیشتری از بیماری قلبی را در مقایسه با بیمارانی که تجربه کردند (۱) نشان دادند. به نظر می‌رسد این ویژگی تأثیر قابل توجهی بر روی هدف دارد.

قند خون ناشتا (fbs): توزیع بین افراد دارای قند خون ناشتا < 120 میلی گرم در دسی لیتر (۱) و افراد بدون آن (۰) نسبتاً مشابه است، نشان می دهد که قند خون ناشتا تأثیر محدودی بر پیش بینی بیماری قلبی دارد.

نتایج الکتروکاردیوگرافی در حالت استراحت (restecg): نوع ۱ نسبت بیشتری از حضور بیماری قلبی را نشان می دهد، که نشان می دهد این ویژگی ممکن است بر نتیجه تأثیر بگذارد.

جنسیت (sex): زنان (۱) نسبت کمتری از بیماری قلبی در مقایسه با مردان (۰) نشان می دهند. این نشان می دهد که جنسیت به عنوان یک عامل تأثیرگذار در پیش بینی بیماری قلبی است.

شیب قطعه ST تمرین اوج (slope): شیب نوع ۲ نسبت به طور قابل توجهی بیشتر از حضور بیماری قلبی دارد، که نشان دهنده پتانسیل آن به عنوان یک پیش بینی کننده قابل توجه است.

نتیجه تست استرس تالیم (thal): دسته نقص برگشت پذیر (۲) نسبت به سایر دسته ها نسبت بیماری قلبی بالاتری دارد که بر اهمیت آن در پیش بینی تأکید می کند.

به طور خلاصه:

تأثیر بیشتر بر هدف: ca, cp, sex, slope, thal

تأثیر متوسط بر هدف: restecg

تأثیر کمتر بر روی هدف: fbs

تصمیم گیری برای One-hot encoding:

sex: این یک متغیر باینری با دو دسته (مرد و زن) است، بنابراین نیازی به اینکار ندارد.

cp: نوع درد قفسه سینه را می توان اسمی در نظر گرفت زیرا هیچ رابطه ترتیبی واضحی بین انواع مختلف درد قفسه سینه (مانند آنژین تیپیک، آنژین آتیپیک و غیره) وجود ندارد. باید one-hot encoding انجام شود.

fbs: این یک متغیر باینری (درست یا نادرست) است، بنابراین نیازی به one-hot encoding ندارد.

restecg: این متغیر نتایج الکتروکاردیوگرافی در حال استراحت را نشان می دهد. نتایجی مانند "طبیعی"، "داشتن ناهنجاری موج ST-T"، و "نمایش هیپرتروفی احتمالی یا قطعی بطن چپ"، به نظر نمی رسد که رابطه ترتیبی داشته باشند. بنابراین، باید one-hot encoding انجام شود.

exang: این یک متغیر باینری است (بله یا خیر)، بنابراین نیازی به one-hot encoding ندارد.

slope: این نشان دهنده شیب بخش ST اوج تمرین است. با توجه به توصیفات (Upsloping، Downsloping، Flat)، به نظر می رسد که ماهیت ترتیبی داشته باشد که نظم خاصی را نشان می دهد. بنابراین، نیازی به one-hot encoding نیست.

ca: این تعداد رگ های اصلی رنگ شده توسط فلوروسکوپی را نشان می دهد. همانطور که یک شمارش را نشان می دهد، یک رابطه ترتیبی ذاتی دارد. بنابراین، one-hot encoding نیست.


thal: این متغیر نتیجه تست استرس تالیم را نشان می دهد. حالت های مختلف، مانند "عادی"، "نقص ثابت"، و "عیب برگشت پذیر"، ماهیت اسمی را نشان می دهد. بنابراین، باید one-hot encoding صورت گیرد.

به طور خلاصه:

نیاز به one-hot encoding: cp، restecg، thal

نیازی به one-hot encoding ندارد: sex، fbs، exang، slope، ca

نمودار Heatmap:



همانطور که از نمودار پیداست، ویژگی‌های exng (آثرین ناشی از ورزش)، thalach (حداکثر ضربان قلب)، cp (نوع درد قفسه سینه)، oldpeak (افسردگی ST ناشی از ورزش) بیشترین همبستگی را با output دارند.


Train کردن مدل‌ها:

توجه شود که به علت اهمیت تشخیص دقیق بیماران قلبی، هایپرپارامتر تونینگ بر اساس بالاترین عدد recall کلاس ۱ (بیماران قلبی) صورت می‌گیرد.

1) DecisionTree

در این مدل ما با استفاده از هایپرپارامتر تونینگ بهترین پارامترها را پیدا کرده و جایگذاری می‌کنیم. با بررسی ارزیابی‌های داده‌های تست و ترین متوجه می‌شویم که این مدل اورفیت ندارد.

Decision Tree Visualization



همانطور که قبلاً بررسی کردیم و الان هم از درخت پیداست، ویژگی‌های `thal`, `ca`, `oldpeak`, `slope` نقش اساسی در مسئله ما ایفا می‌کنند.

2) KNN

در این مدل ما با استفاده از هایپرپارامتر تونینگ بهترین پارامترها را پیدا کرده و جایگذاری می‌کنیم. با بررسی ارزیابی‌های داده‌های تست و ترین متوجه می‌شویم که این مدل اورفیت ندارد.

3) Logistic regression

بعد از اسکیل کردن داده‌ها و بررسی داده‌های تست و ترین متوجه می‌شویم که این مدل نیز اورفیت ندارد.

4) SVM

در این مدل ما با استفاده از هایپرپارامتر تونینگ بهترین پارامترها را پیدا کرده و جایگذاری می‌کنیم. با بررسی ارزیابی‌های داده‌های تست و ترین متوجه می‌شویم که این مدل اورفیت ندارد.

5) MLP

این مدل اگرچه خوب جوابگو بود اما متاسفانه دارای اورفیت بود.

Model	Acuraccy	Recall	Precision	F-Score
KNN	0.83	0.81	0.86	0.83
DecisionTree	0.77	0.65	0.87	0.75
LogisticRegression	0.90	0.87	0.93	0.90
SVM	0.86	0.93	0.83	0.88
MLP	0.85	0.87	0.84	0.86

با توجه به اهمیت recall در این مسئله، SVM بهترین جوابگویی را داشته است.